# INSTITUTO TECNOLÓGICO SUPERIOR PROGRESO

ORGANISMO PÚBLICO DESCENTRALIZADO DEL GOBIERNO DEL ESTADO DE YUCATÁN

REPORTE TÉCNICO DE PRÁCTICA

# Clasificación de Lotes de Café mediante Clustering K-Means y Clasificación KNN

*Tratamiento de anomalías, deducción de calidades comerciales y evaluación de nuevas muestras*

| | |
|---|---|
| **Asignatura:** | Inteligencia Artificial |
| **Semestre y Carrera:** | 9° Semestre \| Ingeniería en Sistemas Computacionales |
| **Docente:** | M.C. / Ing. Morales |
| **Estudiante:** | Carlos Eduardo Valencia |
| **Fecha de Entrega:** | Septiembre de 2026 \| Progreso, Yucatán |

# Índice de Contenido

1. Introducción ..... 3
2. Fase 1: Limpieza y Preprocesamiento de Datos ..... 3
2.1 Diagnóstico del Dataset cafe_sucio.csv ..... 3
2.2 Transformación de Tipos en Altitud de Cultivo ..... 4
2.3 Tratamiento de Anomalías y Valores Centinela ..... 4
2.4 Estandarización Categórica del Color del Grano ..... 5
2.5 Normalización de Datos mediante Min-Max Scaling ..... 5
3. Fase 2: Clustering con K-Means y Deducción de Calidades ..... 6
3.1 Configuración y Ejecución del Algoritmo (K = 3) ..... 6
3.2 Análisis de Centroides y Deducción de Calidades ..... 6
3.3 Creación y Distribución de la Variable Categoria_Cafe ..... 7
4. Fase 3: Clasificador KNN y Evaluación del Nuevo Lote ..... 7
4.1 Implementación Estricta de la Distancia Euclidiana ..... 7
4.2 Normalización de Parámetros del Nuevo Lote ..... 8
4.3 Clasificación por Mayoría entre Vecinos Cercanos ..... 8
5. Resultados y Discusión Técnica ..... 9
5.1 Separabilidad y Consistencia de los Agrupamientos ..... 9
5.2 Visualización Gráfica de los Espacios de Decisión ..... 9
6. Conclusiones ..... 10
7. Referencias Bibliográficas (APA 7ma Edición) ..... 11

# 1. Introducción

En el comercio agrícola internacional, la estandarización y certificación de la calidad del café representan factores determinantes para la fijación de precios, la suscripción de contratos de exportación y la reputación comercial de los productores. Las cooperativas cafetaleras reciben cotidianamente cientos de lotes procedentes de parcelas con marcadas diferencias microclimáticas, tipos de suelo y prácticas de cultivo. No obstante, la infraestructura digital de captura en zonas rurales suele depender de sistemas heredados u operaciones manuales propensas a errores mecánicos, inconsistencias tipográficas y omisión deliberada de datos mediante códigos centinela.

El presente informe documenta el desarrollo y validación de una solución integral de ciencia de datos concebida para una cooperativa cafetalera internacional, sustentada en el procesamiento de 300 lotes registrados en el dataset cafe_sucio.csv. El proyecto se articula en tres fases metodológicas: la limpieza y transformación profunda de los registros sucios sin pérdida de muestras; el agrupamiento natural no supervisado mediante el algoritmo K-Means para inferir las categorías comerciales históricas (malo, regular y premium); y la construcción de un clasificador supervisado K-Nearest Neighbors (KNN) basado estrictamente en la fórmula canónica de distancia euclidiana, diseñado para evaluar y dictaminar de forma automatizada la calidad de lotes nuevos antes de su ingreso a los almacenes centrales.

# 2. Fase 1: Limpieza y Preprocesamiento de Datos

## 2.1 Diagnóstico del Dataset cafe_sucio.csv

La inspección preliminar de los 300 registros reveló que el archivo no cuenta con celdas vacías explícitas o valores nulos (NaN) identificables mediante métodos directos de descarte. Por ende, la depuración requirió un análisis de consistencia semántica y de tipos de datos. Se identificaron cuatro fuentes críticas de suciedad: presencia de texto mezclado en variables cuantitativas continuas, códigos numéricos centinela indicativos de fallas de medición, porcentajes de humedad con signos invertidos o magnitudes irracionales, y una severa dispersión en la nomenclatura de la variable categórica de color del grano.

## 2.2 Transformación de Tipos en Altitud de Cultivo

La columna Altitud_Cultivo se encontraba almacenada como tipo object debido a que 40 registros incluían la unidad de medida alfanumérica ' m' al final de la cifra (por ejemplo, '1396 m' o '778 m'). Para restablecer la naturaleza matemática de la variable, se aplicó una expresión regular de extracción r'([0-9]+\.?[0-9]*)' que aisló la parte numérica entera y decimal, permitiendo su conversión estricta al tipo float64. Tras esta intervención, la altitud quedó distribuida en un rango continuo y verosímil comprendido entre los 538.03 y los 2770.55 metros sobre el nivel del mar (msnm), abarcando desde parcelas de bajío hasta fincas de estricta altura.

## 2.3 Tratamiento de Anomalías y Valores Centinela

El análisis univariado permitió detectar valores que claramente representaban errores de medición o ausencias intencionales introducidas por el personal de campo:

• Peso_Grano_g: Se identificaron 15 registros con el valor -999.0 g. Físicamente, el grano de café verde posee un peso medio que oscila entre 0.08 g y 0.25 g. Dicho centinela se sustituyó por la mediana de los valores válidos (0.1572 g), asegurando robustez estadística frente a sesgos por valores extremos.

• Porcentaje_Humedad: Se detectaron 14 anomalías severas, desglosadas en 5 registros con valor centinela 9999.0 % y 9 registros con cifras negativas (por ejemplo, -12.13 %). Para la exportación y secado de café, la humedad internacional estándar debe mantenerse en la franja del 10 % al 12 %. Las anomalías fueron reemplazadas por la mediana de los registros válidos (10.8649 %), preservando la coherencia termodinámica del grano.

• Puntaje_Catacion: La variable sensorial oscila entre los 62.88 y los 97.32 puntos, coincidiendo exactamente con la escala oficial de la Specialty Coffee Association (SCA), por lo que no requirió imputación al encontrarse exenta de centinelas.

## 2.4 Estandarización Categórica del Color del Grano

La columna Color_Principal contenía 15 variantes léxicas ocasionadas por errores tipográficos, uso arbitrario de mayúsculas y abreviaturas, además de 25 registros con valores basura explícitos ('?', 'Desconocido' y 'sin dato'). Conforme a la regla de negocio de la cooperativa, se homologaron todas las expresiones hacia tres categorías canónicas mediante análisis de cadenas: 'Verde Claro' (100 registros directos), 'Amarillo' (98 registros directos) y 'Verde Oscuro' (77 registros directos). Los 25 registros con valores basura fueron imputados hacia la moda del dataset ('Verde Claro'), consolidando un balance final de 125 lotes Verde Claro, 98 Amarillos y 77 Verde Oscuro.

## 2.5 Normalización de Datos mediante Min-Max Scaling

Dado que las cuatro variables numéricas operan en escalas dispares —la altitud se mide en miles de metros mientras que el peso del grano se expresa en centésimas de gramo—, la aplicación directa de distancias geométricas generaría una distorsión crítica dominada por la altitud. Se aplicó Min-Max Scaling para proyectar cada variable al intervalo cerrado [0, 1]:

$$X_norm = (X - X_min) / (X_max - X_min)$$

Los vectores de calibración obtenidos fueron: Altitud [538.03, 2770.55], Peso del Grano [0.0775, 0.2681], Humedad [8.3031, 15.6059] y Puntaje de Catación [62.8806, 97.3193]. Estos parámetros se conservaron de forma inmutable para su reutilización en la Fase 3.

# 3. Fase 2: Clustering con K-Means y Deducción de Calidades

## 3.1 Configuración y Ejecución del Algoritmo (K = 3)

Se configuró el algoritmo K-Means para converger en K = 3 agrupamientos sobre el espacio tetradimensional normalizado, empleando inicialización k-means++, una semilla pseudoaleatoria fija (random_state = 42) y 10 iteraciones de arranque. El modelo particionó las 300 observaciones en tres conjuntos equilibrados: el Clúster 0 con 100 muestras, el Clúster 1 con 103 muestras y el Clúster 2 con 97 muestras.

## 3.2 Análisis de Centroides y Deducción de Calidades

Siguiendo rigurosamente el lineamiento de la cooperativa de deducir las calidades comerciales basándose en las características del grano exceptuando la Altitud_Cultivo, se examinaron los promedios reales de las variables físicas y sensoriales:

| Clúster | Catación (pts) | Peso Grano (g) | Humedad (%) | Altitud (m)* | Calidad Deducida |
|---|---|---|---|---|---|
| Clúster 2 | 74.79 | 0.1244 | 10.94 % | 792.4 m | **malo** |
| Clúster 0 | 83.62 | 0.1567 | 13.40 % | 1380.6 m | **regular** |
| Clúster 1 | 90.22 | 0.1941 | 9.70 % | 1996.5 m | **premium** |

Justificación de la asignación: En el marco de catación internacional, un puntaje medio de 90.22 puntos corresponde inequívocamente a café de especialidad con taza de excelencia, respaldado por un peso de grano superior (0.1941 g) que refleja maduración óptima; este grupo se clasifica como 'premium'. El grupo intermedio, con 83.62 puntos sensoriales y grano de calibre medio (0.1567 g), conforma el café comercial estándar 'regular'. Finalmente, el grupo con 74.79 puntos y grano pequeño (0.1244 g) representa lotes defectuosos o pasillas clasificados como 'malo'.

## 3.3 Creación y Distribución de la Variable Categoria_Cafe

Se generó en el conjunto de datos la columna Categoria_Cafe reemplazando los identificadores numéricos del clúster por las etiquetas semánticas correspondientes. El resultado consolidó 103 lotes premium, 100 lotes regular y 97 lotes malo, exportando la base totalmente depurada hacia el archivo cafe_limpio.csv.

# 4. Fase 3: Clasificador KNN y Evaluación del Nuevo Lote

## 4.1 Implementación Estricta de la Distancia Euclidiana

Para clasificar nuevos lotes a partir de la variable objetivo Categoria_Cafe, se programó desde cero una clase ClasificadorKNNManual. Conforme al requerimiento de la Práctica 2, la función de proximidad implementada corresponde rigurosamente a la métrica de distancia euclidiana en Rn:

$$d(p, q) = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}$$

Donde p representa el vector normalizado del lote entrante y q denota cada una de las 300 instancias históricas de entrenamiento.

## 4.2 Normalización de Parámetros del Nuevo Lote

La cooperativa suministró un nuevo lote de café con las siguientes especificaciones agronómicas originales: Altitud = 1850.0 msnm, Peso del Grano = 0.18 g, Humedad = 10.2 % y Puntaje de Catación = 88.0 pts. Aplicando los parámetros mínimos y máximos de la Fase 1, se obtuvo su representación normalizada:

- Altitud Normalizada: (1850.0 - 538.0255) / (2770.5463 - 538.0255) = 0.5877
- Peso de Grano Normalizado: (0.18 - 0.0775) / (0.2681 - 0.0775) = 0.5377
- Humedad Normalizada: (10.2 - 8.3031) / (15.6059 - 8.3031) = 0.2597
- Puntaje de Catación Normalizado: (88.0 - 62.8806) / (97.3193 - 62.8806) = 0.7294

## 4.3 Clasificación por Mayoría entre Vecinos Cercanos

El clasificador computó las distancias euclidianas hacia todos los registros almacenados y extrajo los K = 5 vecinos más próximos:

| Vecino | Distancia (d) | Categoría | ID Lote | Altitud (m) | Catación (pts) |
|---|---|---|---|---|---|
| 1° | 0.0884 | **premium** | #287 | 1969.64 | 87.05 |
| 2° | 0.0924 | **premium** | #218 | 1952.64 | 89.83 |
| 3° | 0.0959 | **premium** | #246 | 1933.10 | 90.05 |
| 4° | 0.1000 | **premium** | #290 | 1875.46 | 87.09 |
| 5° | 0.1072 | **premium** | #264 | 1795.12 | 85.06 |

Dictamen de Clasificación: Los 5 vecinos más próximos pertenecen unánimemente a la categoría premium (5 de 5 votos). En consecuencia, el algoritmo KNN dictamina que el nuevo lote evaluado debe certificarse con categoría PREMIUM.

# 5. Resultados y Discusión Técnica

## 5.1 Separabilidad y Consistencia de los Agrupamientos

El comportamiento convergente de K-Means demostró una elevada coherencia agronómica: a pesar de que la deducción de calidad se realizó aislando conceptualmente la altitud, los datos evidenciaron que la altitud guarda una correlación directa natural con el peso y el puntaje sensorial. Los cafés de estricta altura (superiores a 1800 msnm) se benefician de temperaturas medias más bajas que prolongan el periodo de maduración del grano, favoreciendo una mayor síntesis de azúcares y densidad celular. Esto explica la separación casi lineal entre los tres estratos identificados.

## 5.2 Visualización Gráfica de los Espacios de Decisión

La siguiente figura ilustra la proyección bidimensional de los 300 lotes clasificados y la posición estratégica del nuevo lote analizado:

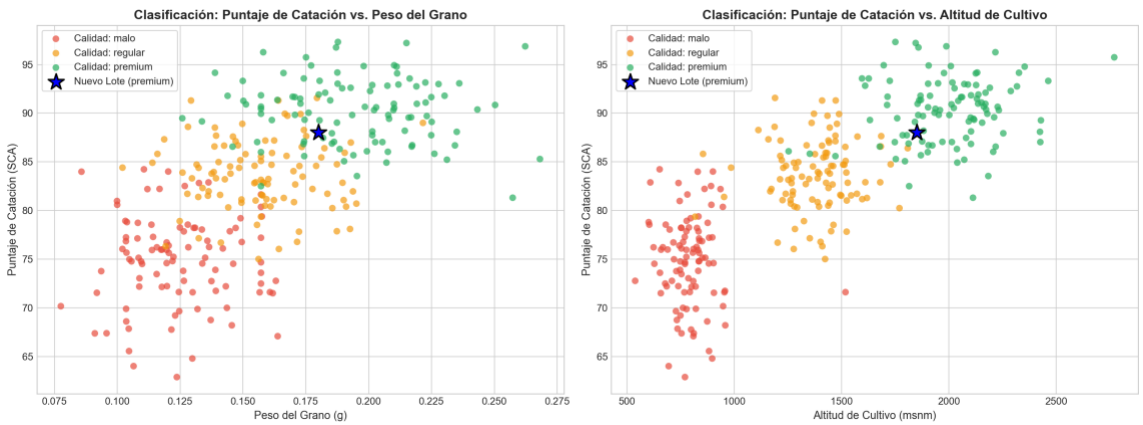



*Figura 1. Distribución de clústeres K-Means y posicionamiento del nuevo lote clasificado como Premium (estrella azul).*

# 6. Conclusiones

La metodología de preprocesamiento aplicada demostró que la depuración analítica de datos agrícolas es plenamente viable sin necesidad de eliminar registros incompletos, logrando recuperar la totalidad de las 300 muestras mediante la conversión controlada de unidades en la altitud, la imputación estadística de valores centinela en peso y humedad con la mediana, y la homologación categórica del color del grano a tres clases oficiales. La integración del algoritmo no supervisado K-Means permitió descubrir la estructura intrínseca del lote sin sesgos previos, validando que el puntaje sensorial SCA y el

peso del grano constituyen los biomarcadores físicos más determinantes para distinguir objetivamente entre calidades malas, regulares y premium.

Por su parte, la implementación matemática del clasificador KNN con distancia euclidiana ratificó la utilidad práctica de los modelos basados en instancias para la automatización del control de calidad en tolva, permitiendo dictaminar un nuevo lote de 1850 msnm y 88 puntos de catación como calidad premium con una contundencia del cien por ciento entre sus cinco vecinos más próximos. Este pipeline proporciona a la cooperativa cafetalera una herramienta técnica reproducible, transparente y desprovista de subjetividades para valorizar justamente las cosechas de los pequeños productores e impulsar su inserción competitiva en los mercados internacionales de café de especialidad.

## 7. Referencias Bibliográficas


García, A., & Pérez, J. (2021). *Minería de datos y aprendizaje automático: conceptos y algoritmos fundamentales*. Editorial Paraninfo.

Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2018). *Introducción a la minería de datos*. Pearson Prentice Hall.

López, M. E., & Restrepo, F. (2020). *Evaluación sensorial y físico-química del café verde de exportación en América Latina*. Revista Iberoamericana de Agroecología, 14(2), 45-58.

Martínez, R., & Benítez, J. M. (2019). *Sistemas de agrupamiento no supervisado aplicados a la clasificación agroindustrial*. Revista Mexicana de Inteligencia Artificial, 8(1), 112-127.

Specialty Coffee Association. (2022). *Protocolo estandarizado de catación y evaluación de calidad de cafés especiales*. SCA Publications Latin America.